

FinLLM Lab v0.2

단일 GPU 금융 Private RAG 의 모델 선택부터 운영 안전성까지

측정 → 오진 수정 → 배포 → 관측 → 회귀 차단 → 복구

On-premise

Qwen3 + AWQ

vLLM

Evaluation

LLMOps

FINAL RELEASE · PASS

actual RTX A6000 통합 rehearsal · 11/11
regression stages PASS

정확도 하나로써는 운영 가능한 구성을 고를 수 없다

외부 API 없이, single GPU 에서, 권한을 지키며, 동시에 응답해야 했다.

DATA

금융 내부문서

합성 corpus 16 개로 외부 유출 없이 검증

COMPUTE

Single A6000

48GiB 한 장 · Kubernetes/multi-node 제외

SERVICE

Concurrency 10

P95 TTFT $\leq 2,000\text{ms}$ · error $\leq 1\%$

QUALITY

Quality ≥ 90

정확성 · 근거성 · 인용 · 거부

SECURITY

ACL violation = 0

권한 필터를 retrieval layer 에서 강제

EVIDENCE

Immutable provenance

model/tokenizer/prompt/eval/config revision

내가 집중한 질문

가장 큰 모델이 아니라, 제한된 GPU 에서 어떤 구성이 실제로 운영 가능한가?

Quality

60-case deterministic evaluation

Latency

server TTFT $\neq$ user TTFT

Throughput

aggregate output tokens/s

Memory

budget $\neq$ process peak $\neq$ native fit

Security

retrieval ACL + injection diagnostics

Reproducibility

immutable revisions + result schema

추정은 후보 선정에만, 최종 판정은 **test · schema · actual run**에만 사용

Requirement 에서 Evidence 까지 하나의 실행 경로로 달았다



OBSERVE

- Prometheus
- Grafana
- 10 alert rules
- DCGM

CHANGE SAFETY

- 153 tests
- 27 result schemas
- 11-stage gate
- immutable rollback

finllm-net 에서 API/vLLM/DCGM target 4 개 모두 up=1

14B AWQ 0.46 eager 를 다음 native 검증 후보로 선택했다

구성	Quality	server P95	user P95	tok/s	Peak	@8192
8B BF16 · 0.50	95.926	77.329ms	1,344.653ms	286.955	24.006GiB	7.31
14B AWQ · 0.50	97.667	129.828ms	1,310.587ms	313.238	23.836GiB	11.05
14B AWQ · 0.46	97.667	129.995ms	1,273.402ms	315.331	21.961GiB	9.53

A6000 · memory-budget-emulation · concurrency 10 · 30 requests · n=3

같은 host/workload 에서 quality 와 memory observation 이 유리했다 . 실제 24GB native fit 은 NOT_EXECUTED.

“AWQ라서 느리다” 는 초기 해석을 통제 실험으로 수정했다

OBSERVE

graph-enabled AWQ

≈57.2 tok/s

8B BF16 보다 크게 느림



HYPOTHESIS

초기 의심

dequant?

weight format 을 원인으로 봄



CONTROL

변수 하나 변경

--enforce-eager

model/revision/eval 고정



EVIDENCE

eager AWQ · n=3

313.238 tok/s

저성능 현상 소멸

수정된 결론: 이 환경의 저성능은 graph-enabled path 와 함께 나타났다. 정확한 kernel root cause 는 NOT_MEASURED.

예상과 다른 결과를 설명으로 덮지 않고 변수를 통제해 다시 측정

v0.1 measurement stack 을 실제 운영 closed loop 로 확장했다

v0.1

Inference + Evaluation

- RAG / ACL
- 60-case evaluation
- Load test
- GPU profiling
- Result schema



v0.2

Serving + Reliability

- Pinned containers
- Health / readiness / metrics
- Prometheus / Grafana
- Regression gate
- Incident / rollback

PASS

Deterministic suite

153 tests

GPU opt-in 3 개는 별도 actual run PASS

PASS

Regression gate

11 / 11

60 문항 · skipped 0

PASS

A6000 Compose

API + vLLM

health/ready/metrics/RAG actual

API 중단을 탐지하고 immutable image 로 복구했다

BASELINE 4 targets up ready=200 API · vLLM · DCGM · Prometheus	DRAIN SIGTERM 20 / 20 in-flight body 완주	ALERT GatewayDown 43.765s state=firing	FAIL CLOSED SHA mismatch state 유지 첫 rollback 차단	ROLLBACK known-good digest 6.332s restart + verify	RECOVER ready + build_info VERIFY OK active alert 없음
--	---	--	---	--	--

graceful drain, symptom alert, immutable provenance, readiness verification 이 한 incident 에서 연결됐다.

의도적 loopback 실험이며 실제 고객 downtime 은 NOT_MEASURED.

LLM 을 구현자와 검토자로 쓰되 최종 판정권은 주지 않았다

Codex · A

Serving / Deployment

- service/
- deploy/
- service tests

Claude · B

Observability / Reliability

- monitoring/
- ops/
- regression / CI

Interface Contract



Independent Build



Cross Review



Reproduction



Deterministic Fix



Actual A6000

- generation failure 인데 readiness=200
- HTTP body 전에 in-flight 감소
- stale/skip gate fail-open
- failed restart state mutation

**LLM opinion < test · schema · command
output · actual GPU evidence**

도구보다 중요한 것은 경계와 실패 판정이었다

GPU memory

executor budget $\neq$ process peak $\neq$ native card fit

Latency

server TTFT $\neq$ queue wait $\neq$ user TTFT

Quantization

weight format 과 execution path 를 분리

Readiness

liveness, dependency, admission 을 분리

Prometheus

name 뿐 아니라 type · labels · buckets 가 contract

Regression

stale · skip · crash 가 fail closed 인지 확인

Rollback

immutable target $\rightarrow$ restart $\rightarrow$ ready $\rightarrow$ state commit

Provenance

source 없는 숫자는 재사용 가능한 evidence 가 아님

완료 범위와 아직 주장할 수 없는 것을 분리했다

KNOWN

Prompt injection

1 / 5 success

Next · defence experiment; threshold 임의 변경 금지

PENDING

Alert windows

PENDING_THRESHOLD_VALIDATION

Next · 실제 traffic distribution 으로 재측정

PENDING

Native 24GB GPU

NOT_EXECUTED

Next · 같은 revision/config native validation

SCOPE

High availability

single-host only

Next · 현재 프로젝트 범위 밖

SCOPE

Production corpus

synthetic 16 docs

Next · 보안 승인된 별도 평가

PENDING

Remote GPU CI

NOT_EXECUTED

Next · self-hosted A6000 runner 연결

PASS · v0.2 single-A6000 scope 통합 운영 rehearsal 통과는 native 24GB/ 실사용 traffic 검증 을 의미하지 않는다 .

모델 비교를 운영 가능한 증거 체계까지 확장했다

단일 RTX A6000 금융 RAG 에서 품질 ·TTFT· 처리량 ·VRAM·ACL 을 동일 provenance 로 비교했습니다 . AWQ 저성능 해석을 eager 통제 실험으로 수정하고 , pinned Compose·Prometheus· 회귀 gate·incident·immutable rollback 까지 실제 실행으로 단았습니다 .

CORE STACK

Python

PyTorch

vLLM 0.9.2

Qwen3

AWQ

Docker Compose

Prometheus

Grafana

GitHub Actions

NEXT

- Quantization Autopsy
- Whisper / K-Voice
- Master's Thesis

AI agents implemented and reviewed. Contracts, tests, schema and measurements judged.