

FinLLM Lab v0.2

모델 실험을 운영 가능한 LLM 서비스로

금융 Private RAG · single GPU · evidence-driven engineering

Python

vLLM

Docker

Prometheus

GitHub Actions

PRODUCTION LLMOPS · PASS

actual RTX A6000 통합 rehearsal · 11/11
regression stages

실험 코드에서 운영·복구까지 하나의 제품 경계로 구현했다

내 역할은 모델 호출 데모가 아니라, 실패를 탐지하고 안전하게 되돌릴 수 있는 LLM 서비스 구축이었다.

SERVICE

API lifecycle

health · readiness · metrics · RAG endpoint · graceful drain

DEPLOY

Pinned runtime

API/vLLM image · Compose · non-root · read-only filesystem

EVALUATION

Reproducible evidence

60 cases · result schema · immutable revisions · n=3

OBSERVE

Production signals

Prometheus · Grafana · DCGM · 10 alert rules

CHANGE SAFETY

Fail-closed gate

stale · skipped · crashed evaluation을 PASS로 처리하지 않음

RECOVERY

Incident & rollback

immutable target · restart · readiness · state commit

금융 RAG는 정확도 하나만으로 운영 구성을 고를 수 없다

외부 API 없이, single GPU에서, 권한을 지키며 동시에 응답할 수 있는가?

Quality

correctness · grounding · citation · abstention

Latency

P95 user TTFT $\leq$ 2,000ms

Throughput

concurrency 10 · 30 requests · n=3

Memory

budget $\neq$ process peak $\neq$ native fit

Security


retrieval ACL violation = 0

Reproducibility

model · prompt · eval · retriever provenance

추정은 후보 선정에만 사용하고, 최종 판정은 test · schema · actual run으로 제한

요청 경로와 운영 제어면을 분리하고 같은 증거 체계로 연결했다



OBSERVE

- Prometheus + Grafana
- DCGM GPU metrics
- 10 alert rules
- incident runbook

CHANGE SAFETY

- 153 tests
- 27 result records
- 11-stage gate
- immutable rollback

actual rehearsal: API · vLLM · DCGM · Prometheus targets 4/4 up

폴더 구조가 곧 책임 경계와 검증 지점이다

service/app.py HTTP contract health · ready · metrics · RAG 요청/응답	service/runtime.py Runtime state startup validation · admission · failure latch · drain	service/inference.py Inference adapter vLLM 호출 · streaming · model provenance	scripts/rag_eval.py Evaluation 60문항 deterministic scoring · ACL · injection
scripts/regression_gate.py Release gate CPU/GPU 11 stages · stale/skip/crash fail closed	deploy/ Deployment digest-pinned containers · Compose · validation scripts	monitoring/ Observability metrics contract · dashboard · PromQL alert rules	ops/ Operations release manifest · incidents · evidence · rollback

14B AWQ eager를 다음 native 검증 후보로 선택했다

구성	Quality	server P95	user P95	tok/s	Peak	@8192
8B BF16 · 0.50	95.926	77.329ms	1,344.653ms	286.955	24.006GiB	7.31
14B AWQ · 0.50	97.667	129.828ms	1,310.587ms	313.238	23.836GiB	11.05
14B AWQ · 0.46	97.667	129.995ms	1,273.402ms	315.331	21.961GiB	9.53

RTX A6000 · memory-budget-emulation · concurrency 10 · 30 requests · n=3

같은 host/workload에서 14B AWQ가 quality와 memory observation에 유리했다. 실제 24GB native fit은 NOT_EXECUTED.

“AWQ라서 느리다”는 초기 해석을 통제 실험으로 수정했다



수정된 결론: 저성능은 이 환경의 graph-enabled path와 함께 나타났다. 정확한 kernel root cause는 NOT_MEASURED.

예상과 다른 결과를 설명으로 덮지 않고, 반증 가능한 변수로 다시 측정

정상 경로보다 실패 경로를 먼저 계약했다

서비스가 살아 있다는 것과 요청을 받아도 된다는 것은 다른 상태다.

/health

API process liveness만 반환

/ready

retriever · inference · model · admission

Startup

revision/config 불일치 시 exit 2

Drain

새 요청 503 · accepted body는 완료

Failure latch

generation 실패 후 readiness 차단

No fallback

silent model/prompt fallback 금지

failure · stale output · skipped stage · restart mismatch를 모두 non-zero로 차단

API 중단을 탐지하고 immutable image로 복구했다

BASELINE

4 targets up

ready=200API · vLLM · DCGM ·
Prometheus**DRAIN****SIGTERM****20 / 20**in-flight response body 완
주**ALERT**

GatewayDown

43.765s

Prometheus state=firing

FAIL CLOSED

SHA mismatch

state 유지

잘못된 rollback 차단

ROLLBACK

known-good

6.332s

digest restart + verify

RECOVER

ready + build

VERIFY OK

active alert 없음

graceful drain, symptom alert, immutable provenance, readiness verification을 한 incident에서 연결했다.

의도적 loopback 실험이며 실제 고객 downtime은 NOT_MEASURED.

실행되지 않은 검증이 PASS로 보이지 않도록 gate를 닫았다

CHANGE INPUTS

변경 가능한 요소

- service / deployment code
- model · tokenizer revision
- prompt · retriever
- evaluation dataset
- monitoring / rollback policy



FAIL-CLOSED GATES

release 판정 조건

- deterministic tests
- result schema validation
- CPU/GPU live evaluation
- ACL / injection regression
- manifest / readiness verify

PASS Deterministic suite

153 tests

GPU opt-in 3개는 actual run 별도 PASS

PASS Result contract

27 / 27

schema · provenance · evidence type

PASS Regression gate

11 / 11

60 cases · failed 0 · skipped 0

완료 범위와 아직 주장할 수 없는 것을 분리했다

KNOWN Prompt injection 1 / 5 success Next · 방어 실험과 별도 threshold 검증	PENDING Alert windows PENDING_THRESHOLD_VALIDATION Next · 대표 traffic 분포로 재측정	PENDING Native 24GB GPU NOT_EXECUTED Next · 동일 revision/config native validation
SCOPE High availability single-host only Next · 현재 프로젝트 범위 밖	SCOPE Production corpus synthetic 16 docs Next · 보안 승인된 별도 평가	PENDING Remote GPU CI NOT_EXECUTED Next · self-hosted runner 연결
PASS · v0.2 single-A6000 scope 통합 운영 rehearsal 통과는 native 24GB 또는 실제 고객 traffic 검증을 의미하지 않는다.		

모델 비교를 운영 가능한 증거 체계까지 확장했다

금융 RAG에서 품질·TTFT·처리량·VRAM·ACL을 같은 provenance로 비교했습니다. 이어 pinned Compose·readiness·Prometheus·회귀 gate·incident·immutable rollback을 실제 A6000에서 검증했습니다.

CORE STACK

Python

PyTorch

vLLM 0.9.2

Qwen3

AWQ

Docker Compose

Prometheus

Grafana

DCGM

GitHub Actions

ROLE FIT

- LLMOps Engineer
- AI Backend Engineer
- Inference Engineer

GitHub · github.com/kkkimdaegyun/finllm-lab