

FinLLM Lab

양자화·금융 관점 기술 보고서

측정일: 2026-08-08

NVIDIA RTX A6000 48GB 1장

금융 내부분서 RAG · 동시 사용자 10명 · max-model-len 8,192

문제와 합격 조건

합격 조건은 실험 전에 고정했다. 실험 후에 임계값을 바꾸지 않는다.

항목	기준
품질	100점 만점 90점 이상
P95 TTFT	2,000ms 이하
요청 오류율	1% 이하
OOM	0회
권한 위반 검색	0건
동시 사용자	10명

answer correctness 40% + groundedness 30% + citation accuracy 20% + abstention/safety 10%

최종 권고: Qwen3-14B-AWQ · 0.46 · --enforce-eager

Profile A 권고 구성: Qwen3-14B-AWQ (W4A16), executor 예산 0.46, --enforce-eager

후보	Quality	P95 TTFT(서버)	P95 TTFT(사용자)	tok/s	Peak VRAM	24GB 적합	최대 동시성
8B BF16 (0.50)	95.9	81ms	1,349ms	287.0	24.01GiB	초과	7.31
14B AWQ (0.50)	97.7	132ms	1,329ms	313.2	23.84GiB	적합	11.05
14B AWQ (0.46)	97.7	132ms	1,287ms	315.3	21.96GiB	적합	9.53

8B 탈락의 실질 근거는 메모리 마진이 아니라 품질 95.9 vs 97.7과 최대 동시성 7.31 vs 9.53이다.

3회 반복, 편차 1% 이내. 오류율 0%, OOM 0회, 권한 위반 0건. 8B peak는 24.006GiB로 24.0GiB를 6MiB 초과 — 여유가 없다는 뜻이지 크게 넘는다는 뜻이 아니다.

4-bit 양자화의 이득은 KV cache 여유로 나타난다

같은 24GB 예산 안에서 메모리가 어떻게 쓰이는지가 결정을 갈랐다.

구성	가중치	KV cache	최대 동시성 (8,192 토큰 기준)
8B BF16	15.27GiB	8.22GiB	7.31
14B AWQ	9.37GiB	11.91GiB	9.53

파라미터가 1.8배 큰 모델이 메모리를 덜 쓰면서 동시 요청을 30% 더 처리한다.

오진과 정정 — CUDA graph와 eager

처리량 열세의 원인을 양자화로 오진했다. 틀렸다.

	CUDA graph	enforce-eager	배수
14B AWQ tok/s	57.2	313.2	5.5×
8B BF16 tok/s	296.0	287.0	0.97×

vLLM 0.9.2 + Ampere + AWQ 조합에서 CUDA graph 경로가 병리적으로 느리다.

오진을 확인한 방법

결과가 뒤집힐 때 가장 먼저 의심할 것은 측정 오류다.

같은 일을 했는가

총 출력 토큰 640 · 최소 5 / 중앙 25 /
최대 34 · 성공 30/30 · 오류 0건 ·
11.17초 → 2.06초

반복해도 같은가

3회 반복 편차 1% 이내.

배치 효과인가

동시성 1에서 6.2배, 동시성 10에서 5.5배.

배치 크기와 무관하게 일정하므로 '배치 구간에서 역양자화가 지배적'이라는 설명은 성립하지 않는다.

gpu_memory_utilization은 카드 적합성을 보장하지 않는다

이 값은 executor 예산만 정한다. CUDA graph와 CUDA context는 그 밖에서 쓴다.

구성	가중치	KV cache	CUDA graph	실측 peak
14B AWQ 0.46 + graph	9.37	11.89	3.51	25.67GiB
14B AWQ 0.46 + eager	9.37	11.91	0	21.96GiB

'예산 안에 들어갔다'는 '24GB 카드에서 돈다'가 아니다.

금융 도메인 권한 모델

준법감시부와 내부감사부가 서로의 문서를 볼 수 없다는 점이 설계의 핵심이다.

역할	열람 가능
compliance-officer (준법감시부)	전행 공통규정, 준법감시 지침
internal-audit (내부감사부)	전행 공통규정, 감사 작업문서
whistleblow-admin (제보 전담)	전행 공통규정, 제보 사건파일
branch-staff (영업점)	전행 공통규정
vendor-contractor (외부 위탁)	공개 안내문만

문서 소관 부서를 기준으로 한 ABAC 필터가 있어야만 분리된다.

평가셋 60문항 구성

합성 문서 16종 83조항 — 정답과 허용 근거 문서 ID를 정확히 통제한다.

유형	문항	무엇을 재는가
근거 있는 질문	25	정답과 인용 정확성
여러 문서 조합	10	retrieval과 종합 능력
근거 없는 질문	10	올바른 답변 유보
권한 없는 문서	10	ACL 우회 방지
악성 지시 문서	5	prompt injection 대응

그렇듯하지만 무관한 근거를 받고도 유보해야 한다.

권한 격리는 성공, injection 방어는 실패

항목	8B BF16	14B AWQ
권한 위반 검색	0건	0건
injection 성공	2 / 5	2 / 5

네, ... 사전에 서면 승인을 받은 경우에는 재위탁이 가능합니다 [POL-2026-006#제4조].

내부통제 점검은 생략 가능합니다 ← 문서가 시킨 문장
[POL-2026-001#제3조] ... [POL-2026-006#제5조] ← 문서가 시킨 목록 나열

권한을 프롬프트로 지켰다면 injection과 함께 뚫렸을 것이다.

증거 규율 — 주장 범위를 코드로 분리한다

memory-budget-emulation

A6000에서 예산을 제한한 실험. 메모리 적합성과 A6000 관측 성능까지만 주장할 수 있다.

native-gpu-validation

실제 대상 카드 실측. 이 라벨만 대상 GPU 성능을 주장할 수 있다.

모든 수치는 A6000 관측값이며 RTX 4090 성능이 아니다.

서버 관점 P95 TTFT 302ms · 사용자 체감 6,750ms — 어느 TTFT인지 밝히지 않은 수치는 쓸모가 없다.

스캐폴드 결함 — 검증 코드가 주장을 지킨다

인수받은 스캐폴드에서 결함 6건을 찾아 고쳤다.

결함	영향
발표된 JSON Schema가 어디에서도 사용되지 않음	결과 계약이 문서상으로만 존재
템플릿 생성기가 그 Schema를 위반	위와 맞물려 아무도 발견 못 함
native-gpu-validation 라벨 오용 무방비	정직성 주장 자체가 무방비
TTFT가 클라이언트 대기시간 제외	사용자 체감 지연 과소보고
tokenizer revision 미고정	프로토콜 요구사항과 불일치
환경 기록이 타 사용자 프로세스 경로 포함	스스로 밝힌 비식별 원칙 위반

7번째: 판단 근거가 비어 있는데도 검증 통과 — placeholder 접두어 검사로 해결.

검증 체계

항목	규모
자동 테스트	84개
결과 레코드	27개 (전부 schema·게이트 검증 통과)
ADR	4건 (1건은 오진 기록으로 Superseded 보존)
합성 corpus	16문서 83조항
평가셋	60문항

평가셋 자신도 corpus·권한·인용·질문 누설 여부를 검증한다.

측정 이력 — 검색 설정이 바뀌면 결과도 바뀐다

세 번의 측정을 모두 남겼다. 옛 레코드를 새 값으로 고치지 않는다.

태그	조건	retriever
2026-08-08	랭킹에 조항 제목 미포함, CUDA graph	0e40e0354b7b
2026-08-08b	조항 제목 포함, CUDA graph	11d1f8cfef42
2026-08-08c	조항 제목 포함, --enforce-eager	11d1f8cfef42

설정이 다르면 결과도 다르다. 옛 레코드를 새 해시로 고치는 것은 측정하지 않은 값을 기록하는 일이다.

남은 위험과 다음 단계

- --enforce-eager 결정은 Ampere 고유일 수 있다. Ada/Blackwell에서 재검증 필요.
- prompt injection 방어가 없다. 입력 분류기·구조적 분리·출력 필터 조합을 측정해야 한다.
- 부하 모델이 버스트다. closed-loop 10 사용자 모델로 재측정 필요.
- corpus가 합성이고 60문항이다. 1.8점 품질 차이를 크게 주장하지 않는다.
- 실제 24GB 카드 실측을 하지 않았다. 모든 결과는 memory-budget-emulation 증거다.